

Processamento de Linguagem Natural

Classificação de Texto com NLTK e Naïve Bayes

Prof. Me. Luis Vinicius

UniAtenas

MCQ 1 — Pré-processamento

Uma equipe recebe milhares de comentários contendo HTML, pontuação, letras maiúsculas e diferentes formas de uma mesma palavra.

Qual é a principal razão para realizar o pré-processamento?

- A) Aumentar obrigatoriamente a quantidade de palavras.
- B) Transformar o modelo Naive Bayes em uma rede neural.
- C) Reduzir ruídos e tornar os textos mais consistentes.
- D) Garantir que todos os textos tenham exatamente o mesmo tamanho.

MCQ 1 — Pré-processamento

Uma equipe recebe milhares de comentários contendo HTML, pontuação, letras maiúsculas e diferentes formas de uma mesma palavra.

Qual é a principal razão para realizar o pré-processamento?

- A) Aumentar obrigatoriamente a quantidade de palavras.
- B) Transformar o modelo Naive Bayes em uma rede neural.
- C) Reduzir ruídos e tornar os textos mais consistentes.
- D) Garantir que todos os textos tenham exatamente o mesmo tamanho.

Resposta: C

O pré-processamento reduz ruídos e padroniza os textos, facilitando a extração de informações relevantes.

MCQ 2 — Bag of Words

Considere o vocabulário:

[bom, ruim, produto]

O texto é:

bom produto bom

Qual representação por contagem é correta?

- A) [1, 1, 1]
- B) [2, 0, 1]
- C) [0, 2, 1]
- D) [2, 1, 0]

MCQ 2 — Bag of Words

Considere o vocabulário:

[bom, ruim, produto]

O texto é:

bom produto bom

Qual representação por contagem é correta?

- A) [1, 1, 1]
- B) [2, 0, 1]
- C) [0, 2, 1]
- D) [2, 1, 0]

Resposta: B

bom aparece 2 vezes, ruim aparece 0 vezes e produto aparece 1 vez.

MCQ 3 — Multinomial Naive Bayes

Um classificador recebe vetores produzidos pela contagem das palavras de cada documento. Qual modelo é particularmente adequado para esse cenário?

- A) Multinomial Naive Bayes
- B) Algoritmo de Dijkstra
- C) Busca em largura
- D) K-means exclusivamente

MCQ 3 — Multinomial Naive Bayes

Um classificador recebe vetores produzidos pela contagem das palavras de cada documento. Qual modelo é particularmente adequado para esse cenário?

- A) Multinomial Naive Bayes
- B) Algoritmo de Dijkstra
- C) Busca em largura
- D) K-means exclusivamente

Resposta: A

O Multinomial Naive Bayes é apropriado para características baseadas em contagens ou frequências de palavras.

MCQ 4 — Naive Bayes

Um classificador recebe uma frase contendo as palavras *excellent* e *wonderful*.
O modelo calcula:

$$P(\textit{positive} \mid \textit{palavras})$$

e

$$P(\textit{negative} \mid \textit{palavras})$$

Qual decisão deve ser tomada?

- A) Sempre escolher *positive*.
- B) Sempre escolher *negative*.
- C) Escolher a classe com maior probabilidade.
- D) Escolher aleatoriamente entre as duas.

MCQ 4 — Naive Bayes

Um classificador recebe uma frase contendo as palavras *excellent* e *wonderful*.
O modelo calcula:

$$P(\textit{positive} \mid \textit{palavras})$$

e

$$P(\textit{negative} \mid \textit{palavras})$$

Qual decisão deve ser tomada?

- A) Sempre escolher *positive*.
- B) Sempre escolher *negative*.
- C) Escolher a classe com maior probabilidade.
- D) Escolher aleatoriamente entre as duas.

Resposta: C

O Naive Bayes compara as probabilidades das classes e seleciona a classe mais provável.

MCQ 5 — Features

Um sistema classifica nomes usando:

`first_letter`

`last_letter`

`suffix_2`

`count_a`

Qual alternativa descreve corretamente essas informações?

- A) São classes produzidas pelo modelo.
- B) São features utilizadas pelo classificador.
- C) São métricas de avaliação.
- D) São conjuntos de treinamento.

MCQ 5 — Features

Um sistema classifica nomes usando:

`first_letter`

`last_letter`

`suffix_2`

`count_a`

Qual alternativa descreve corretamente essas informações?

- A) São classes produzidas pelo modelo.
- B) São features utilizadas pelo classificador.
- C) São métricas de avaliação.
- D) São conjuntos de treinamento.

Resposta: B

Features são características extraídas dos exemplos e fornecidas ao classificador.

Um classificador utiliza apenas a última letra dos nomes. Depois, passa a utilizar as duas últimas letras.

Por que essa alteração pode melhorar o resultado?

- A) Porque duas letras sempre garantem 100% de acurácia.
- B) Porque o sufixo maior pode representar um padrão mais específico.
- C) Porque o classificador deixa de utilizar features.
- D) Porque o conjunto de teste deixa de ser necessário.

Um classificador utiliza apenas a última letra dos nomes. Depois, passa a utilizar as duas últimas letras.

Por que essa alteração pode melhorar o resultado?

- A) Porque duas letras sempre garantem 100% de acurácia.
- B) Porque o sufixo maior pode representar um padrão mais específico.
- C) Porque o classificador deixa de utilizar features.
- D) Porque o conjunto de teste deixa de ser necessário.

Resposta: B

Duas letras podem carregar um padrão mais informativo do que observar apenas a última letra.

MCQ 7 — Quantidade de Features

Um modelo apresentou:

72%

com 3 features e:

72%

com 10 features.

Qual conclusão é mais adequada?

- A) Mais features sempre aumentam a acurácia.
- B) Features adicionais podem não acrescentar informação útil.
- C) O modelo necessariamente está errado.
- D) A quantidade de features determina diretamente a acurácia.

MCQ 7 — Quantidade de Features

Um modelo apresentou:

72%

com 3 features e:

72%

com 10 features.

Qual conclusão é mais adequada?

- A) Mais features sempre aumentam a acurácia.
- B) Features adicionais podem não acrescentar informação útil.
- C) O modelo necessariamente está errado.
- D) A quantidade de features determina diretamente a acurácia.

Resposta: B

Adicionar features não garante melhora. O que importa é a informação que elas fornecem.

Por que separar os dados em treinamento e teste?

- A) Para impedir que o modelo seja treinado.
- B) Para avaliar o desempenho em exemplos não utilizados no treinamento.
- C) Para eliminar todas as features.
- D) Para aumentar artificialmente a acurácia.

MCQ 8 — Treinamento e teste

Por que separar os dados em treinamento e teste?

- A) Para impedir que o modelo seja treinado.
- B) Para avaliar o desempenho em exemplos não utilizados no treinamento.
- C) Para eliminar todas as features.
- D) Para aumentar artificialmente a acurácia.

Resposta: B

O conjunto de teste permite verificar a capacidade de generalização do modelo.

MCQ 9 — isalpha()

Considere:

```
[w for w in tokens if w.isalpha()]
```

Qual é a função de `isalpha()`?

- A) Verificar se a palavra existe no dicionário.
- B) Converter a palavra para minúsculas.
- C) Selecionar tokens formados por caracteres alfabéticos.
- D) Remover palavras repetidas.

MCQ 9 — isalpha()

Considere:

```
[w for w in tokens if w.isalpha()]
```

Qual é a função de `isalpha()`?

- A) Verificar se a palavra existe no dicionário.
- B) Converter a palavra para minúsculas.
- C) Selecionar tokens formados por caracteres alfabéticos.
- D) Remover palavras repetidas.

Resposta: C

`isalpha()` verifica se o token é composto por caracteres alfabéticos.

MCQ 10 — difference()

Considere:

```
unusual = text_vocab.difference(english_vocab)
```

O que está sendo calculado?

- A) Palavras existentes nos dois conjuntos.
- B) Palavras existentes somente em `english_vocab`.
- C) Palavras existentes em `text_vocab`, mas não em `english_vocab`.
- D) Todas as palavras repetidas do texto.

MCQ 10 — difference()

Considere:

```
unusual = text_vocab.difference(english_vocab)
```

O que está sendo calculado?

- A) Palavras existentes nos dois conjuntos.
- B) Palavras existentes somente em `english_vocab`.
- C) Palavras existentes em `text_vocab`, mas não em `english_vocab`.
- D) Todas as palavras repetidas do texto.

Resposta: C

`difference()` retorna os elementos do primeiro conjunto que não estão presentes no segundo.

MCQ 11 — Vocabulário

Um programa encontra:

```
{'spotify', 'google'}
```

como palavras incomuns.

Qual interpretação é mais correta?

- A) São necessariamente palavras incorretas.
- B) São palavras que não aparecem no texto.
- C) São palavras presentes no texto, mas ausentes do vocabulário de referência.
- D) São palavras que o Python não consegue processar.

MCQ 11 — Vocabulário

Um programa encontra:

```
{'spotify', 'google'}
```

como palavras incomuns.

Qual interpretação é mais correta?

- A) São necessariamente palavras incorretas.
- B) São palavras que não aparecem no texto.
- C) São palavras presentes no texto, mas ausentes do vocabulário de referência.
- D) São palavras que o Python não consegue processar.

Resposta: C

A operação identifica palavras presentes no texto que não estão no conjunto usado como vocabulário de referência.

Um classificador acertou 460 de 500 documentos no conjunto de teste.
Qual é sua acurácia?

- A) 46%
- B) 82%
- C) 92%
- D) 96%

Um classificador acertou 460 de 500 documentos no conjunto de teste.
Qual é sua acurácia?

- A) 46%
- B) 82%
- C) 92%
- D) 96%

Resposta: C

$$\frac{460}{500} = 0,92 = 92\%$$

Um pesquisador deseja avaliar um classificador de sentimentos e não quer utilizar somente a acurácia.

Qual alternativa contém métricas adequadas?

- A) Precision, Recall e F1-score
- B) BFS, DFS e Dijkstra
- C) Stemming, tokenização e HTML
- D) Vocabulário, stopwords e stemming

Um pesquisador deseja avaliar um classificador de sentimentos e não quer utilizar somente a acurácia.

Qual alternativa contém métricas adequadas?

- A) Precision, Recall e F1-score
- B) BFS, DFS e Dijkstra
- C) Stemming, tokenização e HTML
- D) Vocabulário, stopwords e stemming

Resposta: A

Precision, Recall e F1-score são métricas utilizadas para avaliar classificadores.

Checklist para a prova

Antes de responder às questões, lembre:

- 1 **Pré-processamento** → reduz ruído e padroniza texto.
- 2 **Tokenização** → texto em tokens.
- 3 **Stopwords** → remove palavras pouco informativas.
- 4 **Stemming** → reduz variações das palavras.
- 5 **BoW** → texto em vetor de contagens/frequências.
- 6 **Naive Bayes** → compara probabilidades das classes.
- 7 **MultinomialNB** → adequado para contagens.
- 8 **Feature** → característica utilizada pelo modelo.
- 9 **suffix_2** → pode capturar padrão mais específico.
- 10 **Treino/teste** → avaliar generalização.
- 11 **difference()** → elementos do primeiro conjunto ausentes no segundo.
- 12 **Acurácia** → proporção de acertos.